

Análise de Dados de um Inversor Trifásico

Cleyton Geraldo Paula Maciel, Danilo Naime Valles Moreira, Thales da Cunha Tobias

Julho de 2026

Sumário

Introdução

- Contextualização

- Informações do Dataset e do Sistema

- Objetivo Geral e Específico

Metodologia

- Regressão Linear Múltipla

- Regressão Não Linear (Polinomial)

- RandomForestRegressor

- Resultados Gerais

- Conclusão

Introdução

Contextualização

- **Cenário Atual:** Importância dos motores de Indução.
- **Técnica:** Controle Vetorial de Campo.
- **O problema:** Imprecisões e instrumentação cara.
- **Responsividade:** Demora em abordagens analíticas.

A Solução Proposta

- Criar modelos computacionais que estimem as tensões reais de saída do inversor através de outros sensores já disponíveis no sistema, viabilizando o projeto economicamente.

Informações do Dataset

Origem dos Dados

Fornecido pelo Departamento *LEA (Power Electronics and Electrical Drives)* da Universidade de Paderborn, Alemanha. Baseado nos dados descritos por Stender et al. (Kaggle, 2020).

Características e Propósito:

- Consiste em dados reais de um Inversor Trifásico (Three-Phase IGBT Two-Level Inverter).
- Artigo de Descrição.
- O propósito é proporcionar um conjunto de dados íntegro e robusto para a construção de modelos preditivos e fins acadêmicos.

Estrutura do Sistema




Figura 1: Arquitetura do Sistema (Retirado do Artigo Base)(Stender et al. 2020)

Symbol	Description	Values
Inverter: SEMIKRON Semiteach IGBT		
I_N	Rated output current	30 A
U_N	Rated output voltage	400 V
U_{dc}	DC-link voltage	560 V
Induction motor: LUST ASH-22-20K13-000		
T_N	Nominal torque	4.7 Nm
I_N	Nominal phase current (star connection)	3.9 A
P_N	Nominal power	1.5 kW
n_N	Nominal speed	3000 1/min
Induction motor: identified T-ECD parameters		
R_s	Stator resistance	2.934 Ω
R_r	Rotor resistance	1.355 Ω
L_m	Mutual inductance	143.8 mH
L_s	Stator inductance	149.6 mH
L_r	Rotor inductance	149.6 mH
p	Number of pole pairs	2

TABLE II: Measurement and control equipment

Device	Product name
Scope	Teledyne LeCroy 12-bit HDO4104
Differential Probes	1 x PMK Bumblebee 1 kV CAT III, 2 x Teledyne LeCroy ADP305
Phase-current sensors	3 x SENSITEC CMS2015 SP10
RCPS	dSPACE MicroLabBox

Figura 2: Parâmetros dos Equipamentos

Estrutura do Sistema




Figura 3: Malha de Controle (Retirado do Artigo Base (Stender et al.))

Objetivo Geral e Específico

- Obter um modelo preditivo para as tensões médias de saída do inversor (usadas no controle vetorial).

Tabela 1: Estrutura de dados dos modelos Black-box

Modelo/Esquema	Dados	Variáveis
Modelo do Inversor	Entradas	$d_{a,k-3}, d_{b,k-3}, d_{c,k-3}, d_{a,k-2}, d_{b,k-2}, d_{c,k-2}, i_{a,k-1}, i_{b,k-1}, i_{c,k-1}, i_{a,k}, i_{b,k}, i_{c,k}, u_{dc,k-1}, u_{dc,k}$
	Alvos	$\bar{u}_{a,k-1}, \bar{u}_{b,k-1}, \bar{u}_{c,k-1}$

Ferramentas e Abordagem Inicial

O desenvolvimento foi realizado utilizando a linguagem **Python**.

Bibliotecas Utilizadas:

- **Scikit-learn** para a construção e treinamento dos modelos preditivos.
- **Seaborn** para a visualização gráfica dos resultados.

Avaliação de Desempenho:

- Foram criadas **métricas relativas** para avaliar e comparar com maior precisão os resultados obtidos.

Modelos Aplicados (Scikit-learn):

- Regressão Linear.
- Regressão Não Linear:
 - Não Regularizada.
 - Regularizada.
- *Random Forest Regressor*.

Desafios da Modelagem Analítica Tradicional

A modelagem analítica tradicional de inversores de dois níveis enfrenta obstáculos significativos para aplicações de controle em tempo real:

- Efeitos Não Lineares Complexos.
- Inviabilidade Computacional.
- Incerteza de Parâmetros.

Inversor Ideal:


$$\bar{u}_{x,k-1} = d_{x,k-2} \cdot u_{dc,k-2}$$

Erro de Simplificação

Representa a diferença entre a tensão real medida pelos sensores e este valor ideal.

Erro da Simplificação Analítica

Comparação entre Estimativa Simples e Sinal real



Metodologia

Estruturação e Organização




Figura 5: Estrutura de Desenvolvimento

Métricas de Avaliação dos Modelos

- **Erro Médio Absoluto (MAE):**

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **Coeficiente Customizado (R_R):**

$$R_R = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - (d_{x,k-2} \cdot u_{dc,k-2}))^2}$$

- **Custo Computacional:** Avalia o compromisso entre **acurácia** e a **viabilidade de embarque** frente às restrições de controle em tempo real.

Regressão Linear Múltipla

Modelagem Linear: A Abordagem Global

Regressão Linear Global

Aplicação de um único modelo linear para modelar todo o conjunto de dados do inversor.

- **Ponto Positivo:** Redução substancial do erro.
- **Limitações Encontradas:**
 - A distribuição de erros deste modelo ainda se mostrou **larga e bimodal**.
 - Fica evidente que **um** modelo linear falha em capturar as particularidades individuais das sessões ao longo do tempo.

Modelos Individuais (Especialistas)


Uma observação fundamental da análise é a **superioridade estatística** da construção de modelos independentes para cada sessão, em detrimento do modelo global.

- **Melhoria de Desempenho:** A métrica de correlação física (R_R) saltou de aproximadamente 0,84 para **mais de** 0,92.
- **Perfil do Erro:** A distribuição dos erros aproximou-se de um comportamento **unimodal**, altamente concentrada ao redor de zero.

Justificativa Física

Modelos treinados em sessões curtas operam em regiões delimitadas (restringindo a faixa de corrente, por exemplo). Isso força o modelo a atuar em uma zona onde os componentes operam de forma aproximadamente "linear".

Acompanhamento da Tensão - (Sessão de Teste)



Desempenho Regressão Linear




Figura 6: Desempenho

Regressão Não Linear (Polinomial)

Modelo Não Linear - Polinomial

Modelo de polinômios

O modelo é a primeira abordagem não linear das análises

- **Ponto Positivo:** Conseguiu uma redução substancial do erro em comparação à estimativa linear
- A distribuição do erro é mais estreita ainda bimodal
- **Limitações Encontradas:**
- Segue uma tendência enviesada e periódica

Regularização

O modelo polinomial foi regularizado em relação ao número parâmetros utilizando PCA.




Figura 7: Compromisso MAE x Custo Computacional

Modelo Não Linear - Polinomial

Limitação principal para o conjunto de dados

- **Não capta bem mudanças bruscas de sinais**
- **Undershoot e Overshoot:**
 - A tendência pode ser observada no plot do Erro para essa modelagem .





Figura 8: Comparativo Modelos Reg L x Reg NL

RandomForestRegressor



Random Forest: Desempenho Superior

- **Acurácia:** O modelo obteve o melhor desempenho, com coeficientes de determinação (R_R) próximos de 0,998 para as três fases no conjunto de teste.


O Paradigma das Árvores de Decisão

- Modelos de regressão tradicionais (lineares ou polinomiais) tentam aproximar o sistema através de uma única função global e contínua.
- Em contraste, o Random Forest particiona o espaço de operação em diferentes regiões.


Modelagem de Descontinuidades Físicas



Tempo Morto (Discreto)



(b)



(c)

Figura 10: Erro Médio

Análise de Resíduos do Random Forest




Figura 11: Comparação Final

Resultados Gerais

Comparação das métrica MAE entre os modelos




Figura 12: Valor da MAE entre as fases dos modelos

Compromisso




Figura 13: Compromisso MAE x Custo Computacional

Conclusão

Principais pontos de Conclusão

- A melhoria crescente no desempenho dos modelos é seguido de um aumento no custo computacional
- O modelo black box se mostrou adequado a proposta do artigo
- Modelos treinados em sessões individuais apresentam melhores resultados em relação ao modelo global.

- Os valores de erro obtidos no modelo de Random Forest foram próximos de 0.2V, a incerteza associada às medições do sensor.
- A aplicação prática exige um tempo de inferência na casa dos nanosegundos e tempo de programação atual ultrapassa esse limite. Isso indica que a operação deve ser otimizada.
- 50 termos na função polinomial são suficientes para uma boa modelagem

- O modelo Random Forest apresenta um perfil de erro difuso ao passo que os outros modelos exibem faixas verticais repetitivas

