

Análise de Dados de um Inversor Trifásico

Cleyton Geraldo Paula Maciel
Danilo Naime Valles Moreira
Thales da Cunha Tobias

Abril de 2026

Sumário

Introdução

- Contextualização

- Informações do Dataset e do Sistema

- Objetivo Geral e Específico

Leitura, Tratamento e Interpretação Inicial dos Dados

Metodologia e Estatística Descritiva

- Análise Exploratória Inicial

- Correlações entre as Variáveis

Conclusão

Introdução

Contextualização

- **Cenário Atual:** Importância dos motores de Indução.
- **Técnica:** Controle Vetorial de Campo.
- **O problema:** Imprecisões e instrumentação cara.

A Solução Proposta

Criar modelos computacionais que estimem as tensões reais de saída do inversor através de outros sensores já disponíveis no sistema, viabilizando o projeto economicamente.

Informações do Dataset

Origem dos Dados

Fornecido pelo Departamento *LEA (Power Electronics and Electrical Drives)* da Universidade de Paderborn, Alemanha. Baseado nos dados descritos por Stender et al. (Kaggle, 2020).

Características e Propósito:

- Consiste em dados reais de um Inversor Trifásico (Three-Phase IGBT Two-Level Inverter).
- Artigo de Descrição.
- O propósito é proporcionar um conjunto de dados íntegro e robusto para a construção de modelos preditivos e fins acadêmicos.

Estrutura do Sistema




Figura 1: Arquitetura do Sistema (Retirado do Artigo Base)(Stender et al. 2020)

Symbol	Description	Values
Inverter: SEMIKRON Semiteach IGBT		
I_N	Rated output current	30 A
U_N	Rated output voltage	400 V
U_{dc}	DC-link voltage	560 V
Induction motor: LUST ASH-22-20K13-000		
T_N	Nominal torque	4.7 Nm
I_N	Nominal phase current (star connection)	3.9 A
P_N	Nominal power	1.5 kW
n_N	Nominal speed	3000 1/min
Induction motor: identified T-ECD parameters		
R_s	Stator resistance	2.934 Ω
R_r	Rotor resistance	1.355 Ω
L_m	Mutual inductance	143.8 mH
L_s	Stator inductance	149.6 mH
L_r	Rotor inductance	149.6 mH
p	Number of pole pairs	2

TABLE II: Measurement and control equipment

Device	Product name
Scope	Teledyne LeCroy 12-bit HDO4104
Differential Probes	1 x PMK Bumblebee 1 kV CAT III, 2 x Teledyne LeCroy ADP305
Phase-current sensors	3 x SENSITEC CMS2015 SP10
RCPS	dSPACE MicroLabBox

Figura 2: Parâmetros dos Equipamentos (Retirado do 5/41

Estrutura do Sistema




Figura 3: Malha de Controle (Retirado do Artigo Base (Stender et al.))

Objetivo Geral e Específico

- **Objetivos Gerais da Pesquisa:**

1. Obter um modelo preditivo para as tensões médias de saída do inversor (usadas no controle vetorial).
2. Achar os ciclos de trabalho (*duty cycles*) que fornecem essas tensões de forma ideal.

Foco Deste Trabalho

Cumprir a primeira etapa: **Desenvolver e explorar com precisão a base para o modelo** responsável por estimar as tensões médias.

Objetivo Geral e Específico

Tabela 1: Estrutura de dados dos modelos Black-box

Modelo/Esquema	Dados	Variáveis
Modelo do Inversor	Entradas	$d_{a,k-3}, d_{b,k-3}, d_{c,k-3}, d_{a,k-2}, d_{b,k-2}, d_{c,k-2}, i_{a,k-1}, i_{b,k-1}, i_{c,k-1}, i_{a,k}, i_{b,k}, i_{c,k}, u_{dc,k-1}, u_{dc,k}$
	Alvos	$\bar{u}_{a,k-1}, \bar{u}_{b,k-1}, \bar{u}_{c,k-1}$
Esquema de Compensação	Entradas	$\bar{u}_{a,k-1}, \bar{u}_{b,k-1}, \bar{u}_{c,k-1}, d_{a,k-3}, d_{b,k-3}, d_{c,k-3}, i_{a,k-3}, i_{b,k-3}, i_{c,k-3}, i_{a,k-2}, i_{b,k-2}, i_{c,k-2}, u_{dc,k-3}, u_{dc,k-2}$
	Targets	$d_{a,k-2}, d_{b,k-2}, d_{c,k-2}$

Leitura, Tratamento e Interpretação Inicial dos Dados

Ferramentas e Abordagem Inicial

O desenvolvimento: *Jupyter Notebook*.

Ferramentas Utilizadas:

- Linguagem **Python**.
- **Pandas e Numpy** para manipulação dos dataframes.
- **Scikit-learn** para modelagem (caso aplicável).
- **Seaborn e Statsmodels** para visualização e análise estatística.

Tratamento Inicial:

- A importação verificou a sanidade da base.
- Foi confirmado que **não há valores nulos ou faltantes** (Zero NaNs).
- O dataset já se encontrava previamente limpo para análise avançada.

Pandas e Tratamento Inicial

Python (**Pandas e Numpy**)

```
(df.isna().sum()).sum() & (df.isnull().sum()).sum()
```

	n_k	u_dc_k	u_dc_k-1	u_dc_k-2	u_dc_k-3	i_a_k	i_b_k	i_c_k	i_a_k-1	i_b_k-1	...
0	3001.406296	567.985297	567.689956	567.431534	567.948379	2.461991	-1.792057	-0.716639	2.729208	-2.098439	...
1	3001.468250	567.911462	567.985297	567.689956	567.431534	2.292110	-1.556948	-0.757338	2.461991	-1.792057	...
2	3001.527815	567.911462	567.911462	567.985297	567.689956	2.155288	-1.332946	-0.840587	2.292110	-1.556948	...
3	3001.585080	567.653039	567.911462	567.911462	567.985297	2.048768	-1.135788	-0.925686	2.155288	-1.332946	...
4	3001.640131	567.579204	567.653039	567.911462	567.911462	1.952350	-0.918266	-1.027434	2.048768	-1.135788	...

Figura 4: Cabeçalho do Dataframe

$$\sum(\text{Trues}) = \sum(\text{Not a Number}) + \sum(\text{Valores Nulos}) \quad (1)$$

Descrição Inicial dos Dados

- **Variáveis de Entrada.**

- **Amostragem:**

- Taxa de 10 kHz (gatilho via PWM).
- 2500 amostras por pulso de PWM.

- **Lógica Temporal:**

$$amostra_{k-1} = amostra_k ?$$

- **Processamento:** Registro da tensão média calculada ($\bar{u}_{k-1}$).




Figura 5: Estrutura temporal dos dados (STENDER et al., 2020).

Desafios da Modelagem Analítica Tradicional

A modelagem analítica tradicional de inversores de dois níveis enfrenta obstáculos significativos para aplicações de controle em tempo real:

- Efeitos Não Lineares Complexos.
- Inviabilidade Computacional.
- Incerteza de Parâmetros.

Inversor Ideal:


$$\bar{u}_{x,k-1} = d_{x,k-2} \cdot u_{dc,k-2}$$

Erro de Simplificação

Representa a diferença entre a tensão real medida pelos sensores e este valor ideal.

Erro da Simplificação Analítica

Comparação entre Estimativa Simples e Sinal real



Metodologia e Estatística Descritiva

Comportamento Dinâmico de Velocidade do Dataset




Figura 7: Comportamento Dinâmico de Velocidade do Dataset

Análise das Faixas de Amostragem

Faixas principais

Três faixas de velocidade: 500, 1500 e 3000 rpm.

Objetivo: Contemplar toda a faixa de operação do motor.

Comportamento Temporal

Evidência de **quebras temporais** na aquisição. Saltos de velocidade instantâneos violam o princípio físico da inércia.

Hipótese: Há sessões de aquisição independentes.

Análise de Possibilidade de Ordem Cronológica




Figura 8: Relação entre as Amostras

Análise de Dispersão e Dependência Linear

Continuidade e Dimensão

- Indício de Ordem
- Risco de Superamostragem
- Impacto Matemático




Figura 9: Identidade do Lag (Deslocado)

Metodologia e Análise

Utilizando o mesmo método anterior mas deslocando o vetor $d_{a(k-1)}$ obtemos a identidade (exceto em pontos específicos), reforçando a **hipótese**.





Figura 10: Distribuição das Amostras

FFT do Sinal de Corrente



Análise em Frequência e Dados Nominais

- **Análise FFT:** A transformada do sinal de corrente revela uma frequência principal de **100 Hz**.
- **Cálculo da Velocidade Síncrona:** Para um Motor de Indução Trifásico (MIT), utiliza-se a relação:

$$n = \frac{120 \cdot f}{p}$$

Symbol	Description	Values
<i>Inverter: SEMIKRON Semiteach IGBT</i>		
I_N	Rated output current	30 A
U_N	Rated output voltage	400 V
U_{dc}	DC-link voltage	560 V
<i>Induction motor: LUST ASH-22-20K13-000</i>		
T_N	Nominal torque	4.7 Nm
I_N	Nominal phase current (star connection)	3.9 A
P_N	Nominal power	1.5 kW
n_N	Nominal speed	3000 1/min
<i>Induction motor: identified T-ECD parameters</i>		
R_s	Stator resistance	2.934 Ω
R_r	Rotor resistance	1.355 Ω
L_m	Mutual inductance	143.8 mH
L_s	Stator inductance	149.6 mH
L_r	Rotor inductance	149.6 mH
p	Number of pole pairs	2

Figura 12: Características do Inversor e do MIT Adaptado (STENDER et al., 2020).

Análise Probabilística do Ciclo de Trabalho

- Análise estatística da distribuição do ciclo de trabalho ($d_{b,k-2}$).

Resultados Quantitativos

- **Probabilidade no intervalo:**

$$P(0.35 \leq X \leq 0.66) = 0.662$$

- **Esperança Matemática:**

$$E[d_{b,k-2}] = 0.500$$




Figura 13: Dispersão de $d_{b,k-2}$ e $i_{b,k-1}$ para 10.000 amostras (STENDER et al., 2020).

Identificação de Sessões, Interrupções e Superamostragem

Interrupções

$$amostra_{k-1(deslocada)} \neq amostra_k$$


Resultados Obtidos: A lógica empregada identificou exatamente **48 interrupções** no conjunto de dados.

Superamostragem

$$amostra_{k-1} = amostra_k$$

Resultados Obtidos: A lógica identificou valores idênticos entre amostras consecutivas.

Validação da Sessões



Correlação de Pearson: Duty Cycle e Tensão




Figura 15: Recorte da Matriz de Correlação

Correlação de Pearson: Duty Cycle e Tensão




Figura 16: Relação Temporal entre $d_{x(k-2)}$ e $u_{x(k-1)}$

Análise

Causalidade e Alta Correlação

Relação Linear: Tensão de Fase e Duty Cycle

- **Dados Reais (Azul)**
- **Modelo Ajustado (Vermelho)**
- **Método de Ajuste.**
- **Parâmetros Extraídos**




Figura 17: Regressão linear sobreposta aos dados do dataset.

Análise de Dafasagem

Para uma defasagem de **120°**:

$$\rho = \cos(120^\circ) = -0,5$$




Figura 18: Relação A e B: -0.482; B e C: -0.493; C e A: -0.524

Correlação e o Paradoxo de Simpson

- **Foco da Análise:** $(u_{X(k-1)})$.
- **O Peso das Interrupções:** Dados não são contínuos.

A Questão Central

- O comportamento estatístico observado no **conjunto geral** (todos os dados misturados) representa a realidade física do motor?
- Ou essa correlação se altera/desaparece quando analisamos as sessões **individualmente**?

Matrizes de Correlação - Visão Geral e por Sessão




Figura 19: Matrizes de Correlação da Fase A

O Paradoxo de Simpson na Análise de Dados

A Raiz do Paradoxo

O coeficiente de Pearson (r) depende da variância em relação à média global ($\bar{x}, \bar{y}$).

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Dinâmica Real vs. Artefatos de Transição




Figura 20: Dinâmica de Velocidade do Dataset

Dinâmica Real vs. Artefatos de Transição

- Correlação por Sessão (Dinâmica Real)
- Correlação Global (Artefato Estatístico)




Figura 21: Análise da Influência da Dispersão dos Dados nas Correlações

Conclusão

Dinâmica Real vs. Artefatos de Transição

- **Correlação por Sessão (Dinâmica Real):** Reflete o regime permanente. As variáveis oscilam de forma síncrona, respeitando as leis de controle do hardware.
- **Correlação Global (Artefato Estatístico):** A agregação domina o cálculo estatístico pelo deslocamento das médias (saltos), invertendo ou distorcendo a relação real do sistema.

Autocorrelação e Análise de Atrasos Temporais




Figura 22: Matriz Correlação e Correlação Ampliada

Autocorrelação e Análise de Atrasos Temporais

- Aparente Não-Causalidade
- Dinâmica do Sistema
- O Efeito da Autocorrelação
- Análise dos Atrasos (Zoom)

Conclusão

Conclusão e Próximos Passos

- **Viabilidade Comprovada:** É possível estimar as tensões de saída e prescindir de sensores físicos no Controlo FOC.
- **Qualidade dos Dados:** *Dataset* consistente, validando a dinâmica de um sistema trifásico equilibrado.
- **Relação Causal:** Confirmada a forte correlação linear entre o *duty cycle* com atraso ($d_{x(k-2)}$) e a tensão alvo ($u_{x(k-1)}$).

Próximos Passos

Treinar modelos de Regressão (Linear, Árvores de Decisão, Redes Neurais) para prever as tensões u_a , u_b e u_c .

Considerações Finais