

Modelagem da Tensão de Saída de um Inversor Trifásico

Cleyton Geraldo Paula Maciel, Danilo Naime,
Thales da Cunha Tobias

** Departamento de Engenharia Elétrica, Universidade Federal de São João del-Rei, MG.*

Abstract: This work presents the formulation, implementation, and comparison of supervised machine learning models for output voltage estimation in three-phase two-level inverters. Since voltage sensors increase the cost and complexity of electric drive systems, while analytical approaches require detailed knowledge of converter nonlinearities and additional computational effort, data-driven methods emerge as a promising alternative. Linear Regression, Polynomial Regression (with and without regularization), and Random Forest models were implemented, with the latter employed as a nonlinear error compensation approach. The models were evaluated under global and individual modeling strategies using the Mean Absolute Error (MAE), a customized physics-based coefficient of determination metric (RR), and computational inference cost. The results demonstrate a trade-off between predictive accuracy and real-time implementation feasibility, highlighting the capability of machine learning models to capture inverter nonlinearities while considering the computational constraints of embedded control platforms.

Resumo: Este trabalho apresenta a formulação, implementação e comparação de modelos de aprendizado de máquina supervisionado para a estimação da tensão de saída em inversores trifásicos de dois níveis. Como sensores de tensão encarecem o projeto de acionamentos elétricos e a abordagem analítica tem alto custo computacional, abordagens baseadas em dados surgem como alternativas viáveis. Foram implementados modelos de Regressão Linear, Regressão Polinomial (com e sem regularização) e Florestas Aleatórias (Random Forest) atuando como compensadores de erro. Foram avaliadas abordagens de modelagem global e em sessões individuais utilizando métricas de Erro Médio Absoluto (MAE), uma métrica customizada de R^R baseada na física do sistema e custo de inferência computacional. Os resultados indicam um forte compromisso entre acurácia e viabilidade de embarque em hardware com restrições de tempo real.

Keywords: Machine Learning; Voltage Estimation; Two-Level Three-Phase Inverter; Field-Oriented Control; Induction Motor; Random Forest.

Palavras-chaves: Aprendizado de Máquina; Estimação de Tensão; Inversor Trifásico de Dois Níveis; Controle Vetorial; Motor de Indução; Random Forest.

1. INTRODUÇÃO

Motores de corrente alternada (AC), como os motores de indução, são amplamente utilizados na indústria moderna. Em sistemas de controle vetorial em cascata (Figura 1), conhecidos como Field-Oriented Control (FOC), aplicados a motores elétricos trifásicos, a tensão atua como a variável de controle fundamental do sistema. Para garantir um desempenho de controle que seja preciso, eficiente e com alta dinâmica computacional, é obrigatório possuir informações exatas sobre a tensão de fase, especialmente quando se considera uma operação baseada no controle de torque [Thakre and Borse (2020)]. Qualquer desvio entre o valor estabelecido para a tensão e a sua referência real atua como um distúrbio no sistema, levando o acionamento elétrico a um desempenho abaixo do ideal. Apesar dessa exigência de alta precisão, a maioria dos acionamentos elétricos comerciais não realiza a medição das tensões de




Figura 1. Malha de Controle e Estrutura das Medições [Adaptado Stender et al. (2020)]

fase em tempo real devido a restrições de custo associadas à implementação de sensores físicos. Consequentemente, para manter a viabilidade econômica do controle, essas tensões de fase precisam ser estimadas através de modelos matemáticos do inversor. Tradicionalmente, as modelagens analíticas estruturais, conhecidas como abordagens white-box eram usadas. No entanto, a aplicação prática dessa metodologia em um contexto de controle contínuo é dificilmente viável. Isso ocorre devido à presença de diversos efeitos não-lineares de chaveamento, que se manifestam na escala de nanossegundos [Stender et al. (2020)]. Tais distorções derivam de fenômenos como o tempo de intertravamento (interlocking time) [Murai et al. (1987)], componentes parasitas [Kerkman et al. (2003)], [Zhang and Xu (2014)] e o efeito de grampeamento de corrente zero [Urasaki et al. (2004)]. Além da complexidade temporal, a parametrização correta desses modelos analíticos é extremamente difícil devido aos desvios de fabricação dos componentes entre as três fases do sistema [Seyyedzadeh and Shoulaie (2019)] e à falta de informações suficientes nas folhas de dados (datasheets) dos fabricantes. Para contornar as limitações de custo dos sensores e a impraticabilidade dos modelos analíticos tradicionais, abordagens baseadas em dados surgem como uma solução altamente favorável. Ao utilizar conjuntos de dados robustos coletados de operações reais do motor, é possível treinar modelos de inversores e esquemas de compensação com abordagem black-box. O objetivo fundamental desses modelos é estimar a tensão média de fase para cada intervalo de Modulação por Largura de Pulso (PWM) com a maior precisão possível. Essa abordagem contorna a necessidade de compreender fisicamente os efeitos não-lineares, focando apenas na relação entre as variáveis de entrada e saída, resultando em precisões de tensão elevadas que otimizam o desempenho geral do controle FOC.

1.1 Justificativa para a Modelagem Black-Box

A predição exata da tensão de saída de um inversor requer a captura e a modelagem simultânea de múltiplas dinâmicas acopladas. Modelos analíticos baseados em física (white-box) ou parametrizações semianalíticas (gray-box) exigem conhecimento aprofundado dos parâmetros do hardware, da temperatura de junção e da impedância dos cabos. Além da difícil parametrização prática, essas metodologias tendem a perder a fidelidade em regiões de ciclo de trabalho (duty cycle) excessivamente altos ou baixos. Por outro lado, a abordagem empírica de modelagem black-box ignora a formulação de equações físicas intratáveis em prol da regressão direta de dados [Stender et al. (2021)]. Modelos baseados em dados utilizam os sinais disponíveis no próprio sistema de controle para aproximar funções altamente não lineares. Ao inferir o comportamento global do sistema, o modelo black-box absorve os tempos mortos, quedas dos dispositivos, distúrbios de clampeamento por zero e efeitos de capacitâncias de forma holística, permitindo compensação em malha fechada.

2. CONCEITOS PRELIMINARES

Uma formulação simplificada amplamente utilizada para representar inversores PWM considera a tensão média de saída como proporcional ao ciclo de trabalho aplicado

sobre a tensão do barramento CC. Essa relação pode ser expressa por:

$$\bar{u}_{x,k-1} = d_{x,k-2} \cdot u_{dc,k-2} \quad (1)$$

Em que $d_{x,k-2}$ é o ciclo de trabalho (duty cycle) e $u_{dc,k-2}$ é a tensão medida no barramento CC [Rashid (2014)]. Essa abordagem linear fornece uma estimativa inicial útil e é recorrente em análises de modelagem de inversores, servindo como ponto de partida para estudos mais complexos. No entanto, tal simplificação não captura os efeitos não lineares, harmônicos e dinâmicos presentes em sistemas reais. Por isso, neste trabalho utilizamos essa formulação apenas como referência inicial e avançamos para técnicas de aprendizado de máquina, capazes de explorar o conjunto de dados experimentais e construir modelos mais representativos, que evidenciem tanto a linearidade aproximada quanto as variações reais do sistema. Com base na organização do conjunto de dados, dois principais cenários de aplicação são propostos para o controle de inversores orientado por dados. Essas aplicações definem as variáveis de entrada e de saída de acordo com o objetivo pretendido, conforme descrito a seguir. O conjunto de dados pode ser utilizado em duas aplicações principais: modelagem de inversor em caixa-preta e compensação de inversor em caixa-preta [Stender et al. (2020)]. No primeiro caso, medições históricas são usadas para aprender a dinâmica do inversor e estimar as tensões de saída trifásicas. No segundo, medições anteriores do sistema juntamente com as referências de tensão estimadas no primeiro modelo são usadas para prever os ciclos de trabalho compensados, mitigando os efeitos das não linearidades e melhorando o desempenho geral do controle.

Modelo Caixa Preta - Inversor

$$\mathbf{X} = \begin{bmatrix} d_{x(k-3)} \\ d_{x(k-2)} \\ i_{x(k-1)} \\ i_{x(k)} \\ u_{dc(k-1)} \\ u_{dc(k)} \end{bmatrix} \quad \hat{\mathbf{Y}} = \begin{bmatrix} \bar{u}_a(k-1) \\ \bar{u}_b(k-1) \\ \bar{u}_c(k-1) \end{bmatrix} \quad (2)$$

Modelo Caixa Preta - Compensação

$$\mathbf{X} = \begin{bmatrix} \bar{u}_x(k-1) \\ d_{x(k-3)} \\ i_{x(k-3)} \\ i_{x(k-2)} \\ u_{dc(k-3)} \\ u_{dc(k-2)} \end{bmatrix} \quad \hat{\mathbf{Y}} = \begin{bmatrix} d_a(k-2) \\ d_b(k-2) \\ d_c(k-2) \end{bmatrix} \quad (3)$$

2.1 Estrutura do Sistema e Base de Dados

A estrutura experimental foi montada para registrar de forma sincronizada os sinais de um inversor trifásico de dois níveis, baseado em IGBTs, que alimenta um motor de indução trifásico acoplado a uma carga mecânica variável. O sistema opera com controle vetorial e frequência de chaveamento de 10 kHz. Para a aquisição dos dados, o sistema de prototipagem rápida (RCPS) controla o acionamento e coleta variáveis como correntes do estator (fase), tensão do barramento CC, ciclos de trabalho (duty cycles), velocidade do rotor e comandos de chaveamento. Em paralelo, um osciloscópio digital de 12 bits, equipado com sondas diferenciais de alta tensão, mede diretamente




Figura 2. Potência de Saída do Inversor [Adaptado de Murai et al. (1987)]

as tensões pulsantes das três fases. A aquisição no osciloscópio foi feita com uma taxa de amostragem de 12,5 MS/s, resultando em aproximadamente 2500 valores por intervalo PWM. A sincronização exata entre os equipamentos é garantida por sinais de disparo: o sinal de início de PWM, que marca o começo de cada intervalo de modulação, e o Sinal de Gatilho. O dataset resultante desta estrutura integra tanto as tensões médias de fase quanto as demais variáveis elétricas e mecânicas do acionamento. A base final contém cerca de 235 mil amostras, cobrindo diferentes condições de operação do motor. Os dados utilizados foram extraídos do Kaggle Stender et al. (2020).

3. EMBASAMENTO TEÓRICO

Esta seção apresenta os principais mecanismos físicos responsáveis pelas distorções na tensão de saída e discute como essas características fundamentam a adoção de uma abordagem de modelagem baseada em dados.

3.1 Tempos Mortos e Atrasos de Comutação

Para evitar o curto-circuito (fase-terra) no inversor, um tempo morto (t_d ou dead-time) é intencionalmente inserido no comando dos transistores. Durante o tempo morto, a tensão de saída é determinada exclusivamente pela polaridade da corrente do motor, pois a corrente flui pelos diodos de roda livre (Murai et al. (1987)). O comportamento do erro associado ao tempo morto pode ser observado na figura 2. Esse desvio de tensão tem uma altura constante igual à tensão do barramento DC e uma largura igual ao período do tempo morto. Além do tempo morto imposto, existem tempos intrínsecos de atraso de acionamento do gate (na faixa de 400 a 800 ns), tempo de atraso de amostragem e tempos de atraso de propagação de sinal.

3.2 Quedas de Tensão nos Semicondutores

Os modelos ideais assumem os transistores e diodos como chaves perfeitas, mas na prática eles apresentam resistência e tensão de condução não nulas. Durante o período de

condução (estado ON), ocorrem quedas de tensão diretas no transistor IGBT (v_S) e no diodo (v_D). A magnitude da queda de tensão no dispositivo não é estática; ela é uma função direta do nível da corrente de fase, da temperatura de operação do módulo e do ciclo de trabalho (duty cycle).

3.3 Dinâmica dos Dispositivos e Capacitâncias Parasitas

A transição entre os estados de condução e bloqueio dos IGBTs não é instantânea e é fortemente afetada pelas impedâncias parasitas do circuito. A capacitância parasita dos dispositivos de potência, predominantemente a capacitância coletor-emissor (C_{ce}), afeta os tempos de transição de tensão. O tempo de descida da tensão (fall time) de uma fase do inversor depende da magnitude da corrente daquela fase, aumentando exponencialmente quando a magnitude da corrente positiva diminui. Isso ocorre porque, durante o tempo morto, a capacitância parasita inferior precisa descarregar para permitir o fluxo da corrente, e essa duração de descarga aumenta quanto menor for a corrente. [Zhang and Xu (2014)] Devido a esses efeitos parasitários e à dinâmica de chaveamento, o comportamento do inversor torna-se altamente não linear em ciclos de trabalho (duty cycles) muito altos ou muito baixos, podendo ocorrer a supressão de pulsos curtos ou distorções no padrão de pulsos.

3.4 Clampeamento em Corrente Zero (Zero Current Clamp)

O fenômeno de clampeamento em corrente zero ocorre frequentemente próximo ao ponto de cruzamento por zero da corrente de fase. Esse efeito causa uma falha na reversão da polaridade da Tensão de Compensação de Tempo Morto (DTCV) (Inversão da tensão de Compensação para mitigar o erro V_e da figura 2), transformando a própria compensação em uma tensão de distúrbio [Urasaki et al. (2004)]. Métodos convencionais que simplificam a curva de erro assumindo valores simétricos geram distorções significativas na medição da polaridade da corrente e na tensão efetivamente aplicada à máquina. Nessas condições de baixo nível de corrente, uma leitura falsa de polaridade faz com que a tensão de compensação (v_d^{com}) exceda sua amplitude teórica correta, o que degrada substancialmente a qualidade da regulação do controle e aumenta as pulsações de torque.

4. METODOLOGIA

A estratégia de modelagem desenvolvida neste trabalho tem como objetivo estimar as tensões médias de fase por intervalo PWM ($\bar{u}_{a,k-1}$, $\bar{u}_{b,k-1}$, $\bar{u}_{c,k-1}$) de um inversor trifásico de dois níveis. Para lidar com os efeitos não lineares e as restrições computacionais de sistemas embarcados de controle, a modelagem baseada em dados foi estruturada em diferentes abordagens arquiteturais e algoritmos de regressão.

4.1 Abordagens de Modelagem

O teto de precisão e a viabilidade computacional do sistema são definidos pela arquitetura escolhida para organizar o conjunto de dados. Foram avaliadas duas abordagens principais de manipulação e roteamento de dados (Figura 3):

- **Modelo Único (Global):** Esta estratégia consiste em concatenar todos os dados dos diferentes regimes operacionais, englobando as 48 sessões independentes no tempo identificadas no conjunto de dados, para treinar um único algoritmo de predição.

- **Vantagens:** Apresenta grande simplicidade, pois apenas um modelo final é criado e gerenciado para a inferência. Ao ter acesso simultâneo à variância completa dos dados, o modelo aproveita o volume estatístico para evitar um *overfitting* generalizado. Adicionalmente, possui capacidade de interpolação robusta para dados inéditos que se enquadrem entre dois regimes conhecidos.

- **Desvantagens:** Demonstra vulnerabilidade ao Paradoxo de Simpson, visto que forçar um modelo linear a traçar uma média entre fenômenos físicos não lineares e divergentes prejudica a precisão global. Além disso, modelos globais complexos o suficiente para capturar micro-dinâmicas exigem recursos que se tornam um gargalo computacional, inviabilizando o controle em tempo real (ex: 10 kHz) em hardwares limitados.

- **Múltiplos Modelos com Direcionamento (Mistura de Especialistas / Individuais):** Esta arquitetura, baseada no conceito *Piecewise Modeling*, divide o problema de acordo com os regimes de operação. Um mecanismo de classificação identifica o regime atual (a sessão específica de continuidade temporal) e direciona os dados para um modelo treinado de forma exclusiva para aquele cenário.

- **Vantagens:** Garante alta fidelidade física ao isolar as não linearidades específicas de hardware, resultando em métricas preditivas superiores para cada sessão isolada. Por possuírem um escopo estreito, os modelos individuais assumem a forma de matrizes matemáticas reduzidas, otimizando drasticamente o consumo de memória e processamento no microcontrolador. A arquitetura também confere isolamento de falhas, facilitando manutenções direcionadas.

- **Desvantagens:** Exige a orquestração de um roteador lógico que, se cometer erros de classificação, enviará a inferência ao modelo incorreto, gerando erros preditivos severos. Paralelamente, aumenta a complexidade de manutenção dos artefatos de software por gerenciar dezenas de vetores de pesos, fragmenta os dados de treino limitando a amostragem de regimes curtos, e pode inserir atrasos de inferência durante a etapa de roteamento.

4.2 Modelos de Predição Utilizados

Considerando que a relação entre as variáveis de operação do inversor e as tensões de saída pode apresentar diferentes graus de linearidade, optou-se por avaliar modelos de regressão com níveis crescentes de complexidade. Essa estratégia permite investigar desde abordagens de elevada interpretabilidade até algoritmos capazes de representar interações não lineares mais complexas, fornecendo uma análise comparativa entre precisão preditiva, capacidade de generalização e custo computacional. Assim, foram sele-




Figura 3. Diagrama de Desenvolvimento

cionados modelos representativos de diferentes paradigmas de aprendizado supervisionado para a tarefa de predição das tensões de saída do inversor. Para efetuar a previsão das tensões de saída, três famílias de algoritmos foram implementadas e comparadas.

Regressão Linear Múltipla Atuou como o algoritmo base para testar a relação linear direta entre as variáveis preditoras puramente exógenas e a tensão alvo. Este modelo busca encontrar os parâmetros ótimos que minimizem os erros absolutos sem a utilização de termos de regularização no cenário padrão. O modelo foi avaliado tanto na arquitetura de Modelo Global quanto no esquema de Direcionamento (Especialistas), demonstrando o impacto das diferentes arquiteturas sobre os algoritmos.

Regressão Não Linear (Polinomial) Para capturar as dinâmicas físicas não lineares que o inversor exibe, como os tempos de comutação e quedas de tensão nos componentes parasitas, foi implementada uma regressão baseada na expansão polinomial das variáveis de entrada originais.

- **Expansão:** As *features* originais foram transformadas utilizando polinômios de segundo grau, criando um espaço dimensional mais rico antes de aplicar os estimadores lineares.
- **Regularização:** Considerando que o aumento da dimensionalidade eleva o risco de variância alta (sobreajuste), o algoritmo foi otimizado através de um *Pipeline* contendo penalizações. Empregou-se seleção de *features* e redução de coeficientes (utilizando lógicas de regularização Ridge e algoritmos baseados em Lasso) para manter apenas as interações polinomiais que efetivamente traduzem os fenômenos físicos do inversor. A técnica de Análise de Componentes Principais (PCA) também foi aplicada como etapa de pré-processamento, reduzindo a dimensionalidade dos dados e mitigando efeitos de correlação entre as variáveis de entrada.

Florestas Aleatórias (Random Forest Regressor)

Em vez de utilizar o modelo baseado em árvores para prever diretamente a grandeza total da tensão, o *Random Forest* foi empregado estruturalmente em um esquema de compensação física (Modelagem do erro).

- **Física Básica + Predição de Erro:** Inicialmente, o sistema utiliza a equação clássica simplificada de um inversor ideal para calcular a parcela linear e dominante da tensão, descrita na Equação 1.

- **Compensação Não Linear:** O *Random Forest Regressor*, configurado com 50 estimadores e uma profundidade restrita (máximo de 15 divisões por árvore), foi treinado para modelar exclusivamente o resíduo da equação física, ou seja, o desvio causado pelas não linearidades do sistema real. A estimativa final da metodologia corresponde à soma do cálculo algébrico simplificado com a compensação orientada a dados da floresta aleatória.

4.3 Métricas utilizadas para validação do modelo

O Erro Médio Absoluto (Mean Absolute Error - MAE) é uma das métricas mais utilizadas para avaliar modelos de regressão em aprendizado de máquina. Essa métrica mede a média dos erros absolutos entre os valores reais e os valores preditos pelo modelo, fornecendo uma interpretação direta do erro médio na mesma unidade da variável de saída. Como o MAE utiliza o valor absoluto das diferenças, erros positivos e negativos não se cancelam, tornando a métrica de fácil interpretação. Além disso, o MAE é menos sensível a valores extremos (outliers) quando comparado a métricas como o Erro Quadrático Médio (MSE), pois não eleva os erros ao quadrado.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4)$$

em que n representa o número de amostras. A métrica tradicional de R^2 mostra-se ineficiente para este sistema, uma vez que relaciona o resíduo do modelo à média global. Nesse contexto físico, o denominador representaria um erro máximo aceitável que induziria à adoção da média das amostras como solução ótima, o que não condiz com a dinâmica do inversor.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Uma análise alternativa pode ser realizada ao comparar o modelo com a estimativa simples:

$$R^R = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - (d_{x,k-2} \cdot u_{dc,k-2}))^2} \quad (5)$$

Na expressão acima, comparamos os modelos com a equação 1. Se o R^R for maior que 0, o modelo encontrou padrões de não linearidades, que a equação simples ignora. Se menor ou igual a 0, o modelo não conseguiu superar a equação simplificada.

5. RESULTADOS E DISCUSSÕES

5.1 Limitações da Estimativa Ideal e Modelagem Linear

A abordagem mais básica para estimar a tensão de fase baseia-se na equação de um inversor ideal, definida pelo produto entre a razão cíclica e a tensão do barramento CC ($\bar{u}_{ideal,x,k-1} = d_{x,k-2} \cdot u_{dc,k-2}$). Como demonstrado na sessão de teste da figura 4, esta estimativa simples (linha tracejada vermelha) apresenta um desvio significativo em relação ao valor real medido. Este erro expressivo confirma




Figura 4. Comparação entre Valor Real e Estimados na Regressão Linear




Figura 5. Métricas Modelo Linear

a premissa de que efeitos não-ideais, como o tempo de intertravamento (dead-time) e quedas de tensão nos semicondutores, impossibilitam o uso da equação ideal para controle de alta precisão. A aplicação de uma Regressão Linear Global obteve uma redução substancial do erro, contudo, a distribuição de erros deste modelo ainda se mostrou larga e bimodal, evidenciando que uma única equação linear generalizada para o inversor falha em capturar as particularidades individuais das comutações. Uma observação fundamental desta análise é a superioridade estatística da construção de modelos independentes para cada sessão (Modelos Individuais/Especialistas) em detrimento de um modelo global único. A métrica RR saltou de aproximadamente 0,84 para mais de 0,92. A distribuição de erros (Fase A) se aproxima de um comportamento unimodal e significativamente mais concentrada ao redor do zero. Essa melhoria substancial pode ser entendida pela restrição feita na modelagem. Modelos treinados e testados na mesma sessão operam em regiões próximas em que a não linearidade não se destaca de forma acentuada. Ao estabelecer uma região da sessão, restringimos por exemplo a faixa de corrente nos semicondutores, que por sua vez podem estar dentro de uma região aproximadamente "linear".

5.2 Modelagem Não Linear

Buscando mapear os fenômenos não lineares dos semicondutores, visando melhorar o desempenho do modelo global, técnicas mais complexas foram introduzidas. A Regressão




Figura 6. Métricas de Performance




Figura 7. Característica não Linear do Diodo Real [Retirado de Rashid (2014)]

Polinomial de Grau 2 (Global) demonstrou ligeira vantagem sobre a linear global (figura 6). Isso é justificado pela capacidade da modelagem polinomial de grau dois modelar efeitos não lineares de condução dos IGBTs e Diodos (figura 7). A introdução da expansão polinomial proporcionou uma redução de aproximadamente 14 por cento no erro médio absoluto em relação ao modelo linear, indicando que parte das não linearidades presentes no inversor pode ser representada pela inclusão de termos quadráticos e de interação entre as variáveis de entrada. Esses termos permitem modelar relações que não podem ser descritas por uma regressão linear convencional, como dependências simultâneas entre corrente, tensão do barramento e ciclo de trabalho. Além disso, a melhoria observada no coeficiente de determinação permaneceu inferior à obtida pela estratégia baseada em modelos individuais, sugerindo que o comportamento do inversor é caracterizado não apenas por relações não lineares suaves, mas também por diferentes




Figura 8. Comparação Final dos Melhores Modelos

regimes de operação associados a fenômenos como tempo morto, comutação dos semicondutores e cruzamento por zero da corrente. Nesses casos, a segmentação do espaço de operação mostra-se mais eficaz do que a utilização de uma única função polinomial global para representar toda a dinâmica do sistema. A Figura 6 evidencia que a Regressão Polinomial de Grau 2 reduz a dispersão dos resíduos em relação à Regressão Linear Global, concentrando maior parcela dos erros em torno de zero. Entretanto, a Regressão Linear Individual apresenta uma distribuição significativamente mais estreita, confirmando sua maior capacidade de modelar a dinâmica do inversor e justificando o menor erro médio absoluto obtido

5.3 Random Forest

O melhor desempenho foi obtido pelo modelo baseado em Random Forest, que apresentou coeficientes de determinação próximos de 0,998 para as três fases de conjunto de teste. Esse resultado evidencia sua elevada capacidade em representar as não linearidades presentes na tensão de saída do inversor (Figura 8). Diferentemente dos modelos lineares e polinomiais, que aproximam o comportamento do sistema por meio de uma única função global contínua, o Random Forest particiona o espaço de operação em diferentes regiões e constrói aproximações locais para cada regime de funcionamento. Essa característica é particularmente adequada para inversores de frequência, nos quais fenômenos como tempo morto, comutação dos semicondutores, cruzamento por zero da corrente e quedas de tensão nos dispositivos introduzem descontinuidades e mudanças abruptas na relação entre as variáveis de entrada e a tensão aplicada ao motor. Em particular, neste contexto, o erro de predição de tensão decorrente do tempo morto apresenta




Figura 9. Aproximação do Efeito do Dead Time [Adaptado de Murai et al. (1987)]

comportamento aproximadamente retangular (Os pulso causados pelo intertravamento (V_c) são aproximados por seu efeito médio - onda quadrada) [Murai et al. (1987)], evidenciado na figura 9, o que torna sua representação por funções polinomiais menos eficientes. Pois estas, frequentemente estão associadas à suavização das transições ou à necessidade de polinômios de maior ordem, o que pode levar por sua vez a oscilações locais nas proximidades dessas mudanças abruptas - fenômeno de Runge. Em contraste, o particionamento sucessivo do espaço de entrada realizado pelas árvores de decisão permite representar naturalmente esses diferentes regimes de operação e suas transições (possibilitando modelagem semelhante a pulsos retangulares), justificando a superior capacidade preditiva observada para o Random Forest. Também na figura 8 observa-se que o Random Forest apresenta a distribuição de resíduos mais estreita e centrada em zero, indicando que a maior parte das estimativas possui erro reduzido. Esse resultado corrobora as métricas de MAE obtidas anteriormente, evidenciando que o modelo captura de forma mais eficiente a dinâmica não linear do inversor em comparação às abordagens baseadas em regressão

5.4 Análise dos Resíduos

A partir da figura 10 a distribuição dos resíduos evidencia diferenças importantes entre os modelos avaliados. Os modelos Linear e Polinomial apresentam padrões estruturados ao longo da série temporal, com regiões de maior concentração dos erros e comportamento periódico. Esse resultado indica que os resíduos ainda contêm componentes determinísticas, sugerindo que esses modelos não conseguem representar integralmente as não linearidades presentes na dinâmica do inversor. Consequentemente, observa-se a presença de um viés dependente do ponto de operação, característica típica de modelos com capacidade limitada de representação. Em contraste, o modelo Random Forest apresenta resíduos distribuídos de forma mais difusa e aproximadamente centrados em zero, sem padrões periódicos claramente identificáveis. A ausência de estruturas organizadas sugere que a maior parte da relação entre as variáveis de entrada e a tensão de saída foi capturada pelo modelo, permanecendo predominantemente componentes aleatórias. Sob a perspectiva da identificação de sistemas, essa característica indica uma redução do erro sistemático

e um comportamento residual mais próximo daquele esperado para um modelo que representa adequadamente a dinâmica do processo.

5.5 Análise do Erro Médio Absoluto (MAE)

A Figura 11 evidencia a evolução do desempenho dos modelos em termos de erro médio absoluto (MAE). A Regressão Linear Global apresentou o maior erro (4,655 V), seguida pela Regressão Não Linear (3,936 V) e pela Regressão Linear Individual (2,765 V). O Random Forest apresentou o melhor resultado, com MAE de apenas 0,419 V, reduzindo o erro em aproximadamente 91 por cento em relação ao modelo linear global e demonstrando maior capacidade de representar a dinâmica não linear do inversor.

5.6 Compromisso entre tempo de inferência e custo computacional

A Tabela 1 resume o compromisso (trade-off) entre a precisão de estimação e o custo computacional dos modelos avaliados, considerando a Regressão Linear como modelo de referência. Embora a Regressão Não Linear reduza o erro médio absoluto (MAE) em aproximadamente 14 por cento, essa melhoria é acompanhada por um aumento de 2,79 vezes no tempo de inferência e por uma demanda de memória superior a doze vezes em relação ao modelo linear. Em contrapartida, o modelo Random Forest proporciona uma redução expressiva no erro de predição, diminuindo o MAE de 4,61 V para 0,43 V, o que representa uma redução aproximada de 90,7 por cento. Esse resultado evidencia a maior capacidade desse algoritmo em representar as não linearidades presentes na dinâmica do inversor. Entretanto, esse ganho de desempenho é obtido à custa de um aumento significativo na complexidade computacional, exigindo aproximadamente 18 vezes mais tempo de inferência e cerca de 64 mil vezes mais memória que o modelo linear. Considerando que o sistema de aquisição de tensão empregado apresenta uma incerteza da ordem de 0,2 V, o erro obtido pelo Random Forest aproxima-se do limite prático imposto pela própria instrumentação, indicando que reduções adicionais no erro de estimação tendem a proporcionar benefícios cada vez menores. Por fim, ressalta-se que os tempos de execução apresentados foram obtidos a partir de implementações desenvolvidas em Python e, portanto, devem ser interpretados como indicadores relativos da complexidade computacional entre os algoritmos. Em aplicações embarcadas, implementações desenvolvidas em linguagens compiladas, como C ou C++, tendem a apresentar tempos de execução significativamente menores, de modo que a avaliação definitiva da viabilidade em tempo real depende da plataforma de hardware empregada.

6. CONCLUSÕES

Os resultados demonstraram que mesmo os modelos de regressão linear são capazes de representar adequadamente a dinâmica fundamental do inversor, evidenciando que a física dominante do sistema pode ser capturada por relações lineares entre as variáveis de entrada e saída. A análise dos resíduos mostrou que esses modelos apresentam erros relativamente organizados e repetitivos, indicando a




Figura 10. Padrão de Erros de Modelagem

presença de componentes determinísticas ainda não modeladas. À medida que a complexidade dos modelos aumenta, observa-se uma redução progressiva desses erros, evidenciando a incorporação de efeitos não lineares associados ao comportamento dos semicondutores e aos diferentes regimes de operação do inversor. A Regressão Polinomial apresentou ganhos moderados, enquanto o Random Forest foi capaz de capturar de forma mais completa as não linearidades presentes no sistema. Como consequência, seus resíduos tornaram-se mais difusos, distribuídos em torno de zero e sem padrões estruturados evidentes, indicando a redução do erro sistemático e a predominância de componentes aleatórias.

Tabela 1. Relatório de *Compromisso* (Baseline: Linear Global = 1.0x)

Modelo	Erro MAE	Memória	Tempo
Linear (RL Global)	1.00x (4.6082 V)	1.00x	1.00x
Não-Linear (NL Global)	0.86x (3.9523 V)	12.43x	2.79x
Random Forest (Comp)	0.09x(0.4296 V)	63995.06x	18.16x

Fonte: Elaborado pelo autor.




Figura 11. Comparação Geral MAE dos Melhores Modelos

- source inverter for better performance in near zero currents. *IEEE Transactions on Industrial Electronics*, 66(1), 71–78. doi:10.1109/TIE.2018.2823692.
- Stender, M., Wallscheid, O., and Böcker, J. (2020). Data set description: Three-phase igbt two-level inverter for electrical drives. doi:10.13140/RG.2.2.23335.37280.
- Stender, M., Wallscheid, O., and Böcker, J. (2021). Comparison of gray-box and black-box two-level three-phase inverter models for electrical drives. *IEEE Transactions on Industrial Electronics*, 68(9), 8646–8656. doi: 10.1109/TIE.2020.3018060.
- Thakre, M.P. and Borse, P.S. (2020). Analytical evaluation of foc and dtc induction motor drives in three levels and five levels diode clamped inverter. In *2020 International Conference on Power, Energy, Control and Transmission Systems (ICPECTS)*, 1–6. doi:10.1109/ICPECTS49113.2020.9337015.
- Urasaki, N., Senjyu, T., Kinjo, T., Uezato, K., Funabashi, T., and Sekine, H. (2004). Dead-time compensation strategy for permanent magnet synchronous motor drive taking zero current clamp and parasitic capacitor effects into account. In *30th Annual Conference of IEEE Industrial Electronics Society, 2004. IECON 2004*, volume 3, 2718–2723 Vol. 3. doi:10.1109/IECON.2004.1432236.
- Zhang, Z. and Xu, L. (2014). Dead-time compensation of inverters considering snubber and parasitic capacitance. *IEEE Transactions on Power Electronics*, 29(6), 3179–3187. doi:10.1109/TPEL.2013.2275551.

REFERÊNCIAS

- Kerkman, R., Leggate, D., Schlegel, D., and Winterhalter, C. (2003). Effects of parasitics on the control of voltage source inverters. *IEEE Transactions on Power Electronics*, 18(1), 140–150. doi:10.1109/TPEL.2002.807190.
- Murai, Y., Watanabe, T., and Iwasaki, H. (1987). Waveform distortion and correction circuit for pwm inverters with switching lag-times. *IEEE Transactions on Industry Applications*, IA-23(5), 881–886. doi:10.1109/TIA.1987.4504998.
- Rashid, M.H. (2014). *Eletrônica de potência*. Pearson Education do Brasil, São Paulo, 4 edition.
- Seyyedzadeh, S.M. and Shoulaie, A. (2019). Accurate modeling of the nonlinear characteristic of a voltage